Overnet presenta:

Deep Learning per il rischio di credito bancario

per intesasanpaolo

di **Antonio Piemontese**

Novembre 2026





Reti Neurali
per Rischio di credito con Python e PyTorch



Link al sito Overnet

Link al sito WPC26

IL CORSO È ORGANIZZATO DA

OVERNET.

Formazione ICT per aziende e professionisti

30+ ANNI DI ESPERIENZA

Le radici nella storica **Mondadori Informatica Education**

Una lunga esperienza nella formazione IT.

UN'OFFERTA COMPLETA

La più ampia offerta di formazione ufficiale IT*

- Corsi ufficiali e personalizzati
- Academy e certificazioni
- Competenze per aziende e professionisti

ORGANIZZA WPC

DAL 1994

La più importante conferenza italiana sulle tecnologie Microsoft*

Con speaker Microsoft, MVP ed esperti di primo piano del settore IT.

75.000+ persone formate

30.000+ persone certificate

1.000+ aziende clienti

**Posizionamento e dati dichiarati sui siti ufficiali.*

Fonti: overnet.education · wpc.education



ANTONIO PIEMONTESE

Data Scientist · Docente · Consulente

DAL 2010

AI · Machine Learning · Deep Learning

CORSI E CONSULENZE A TEMPO PIENO

Su AI, ML e DL, per aziende e professionisti

PERCORSO FORMATIVO

- Laurea in Informatica a Torino
- 110 e lode
- Specializzazione in AI, ML e DL al Politecnico di Torino

APPLICAZIONI CONCRETE

- Analisi dei dati e modelli predittivi
- Reti neurali e Deep Learning
- AI generativa

ESPERIENZA PROFESSIONALE

- 40+ anni nel settore IT
- Libero professionista dal 2004
- Formazione e consulenza aziendale

Collaborazione con **Overnet** da **15 anni**

linkedin.com/in/antoniopiemontese

Il corso risponde alle esigenze di Intesa Sanpaolo

Overnet · Deep Learning applicato al credito

Più avanti per dettagli

ESIGENZE FORMATIVE		RISPOSTA DEL CORSO
Approfondire il Deep Learning Il Machine Learning è già conosciuto	→	Focus su **reti neurali, sequenze transazionali** ed **embedding**.
Credito, PD e pattern recognition Comprendere i predittori rilevanti	→	Esempi sul **credito** e confronto con **XGBoost** per valutare il contributo del DL.
Valutare la qualità dei modelli Performance delle probabilità di default	→	Discriminazione e calibrazione delle **PD; precision, recall** e **F1** accanto all'accuracy.
Spiegabilità, bias e Vigilanza Comprendere e motivare le scelte	→	**valori SHAP** e **Captum,** stabilità delle spiegazioni e valutazione quantitativa dei **bias.** Prerequisito per Captum: **feature importance.**
Volumi e portafogli diversi Retail, Large Corporate e SME	→	Criteri di scelta adatti sia ai **grandi volumi transazionali** sia ai **portafogli contenuti.**
Didattica frontale e codice disponibile Partecipazione senza installazioni	→	**Demo** sul PC del docente e **notebook** con codice completo, riutilizzabile dopo il corso.

Python · scikit-learn · PyTorch

Formato richiesto: 4 mattine · 2 edizioni replicate · 15 partecipanti per edizione

Obiettivi formativi forniti a Overnet da Intesa Sanpaolo

Giuseppe Giarrizzo · Debora Giuliano · Marco Alberici (vice di Andrey Karpov)

Riunione con Overnet del 15 settembre 2026

Fonte delle esigenze: verbale Digit'Ed / ISP del 15 settembre 2026

INTESA SANPAOLO

Credit Risk Modeling & Scoring

Le tre strutture di Intesa Sanpaolo destinatarie del corso

RETAIL
Debora Giuliano



Grandi volumi di dati

BIG DATA
≈ 10^6 righe
Circa un milione di righe di dati

LARGE CORPORATE
Giuseppe Giarrizzo



Grandi imprese, banche ed enti pubblici

MOLI DI DATI INFERIORI
rispetto al Retail
Portafogli contenuti

SME RETAIL/CORPORATE
Marco Alberici per Andrey Karpov



Piccole e medie imprese
Ambiti retail e corporate

MOLI DI DATI INFERIORI
rispetto al Retail

Un unico corso, tre contesti di applicazione
Metodi ed esempi adeguati ai volumi di dati e alle caratteristiche dei portafogli.

Il corso a colpo d'occhio

Formato

- 4 mattine online, ore 9:00–13:00
- 2 edizioni identiche da 15 analisti
- Italiano · teoria–pratica ≈ 30–70
- 3 pillole + 3 lab guidati a mattina
- Hands-on sui PC dei partecipanti

Stack

Python · scikit-learn · PyTorch

XGBoost: il champion da sfidare

1 **Oltre l'accuracy**
Le metriche attese dalla Vigilanza e i primi passi con PyTorch

2 **Reti su dati tabellari**
Embedding, regolarizzazione, calibrazione; confronto con XGBoost

3 **Sequenze di transazioni**
LSTM sui movimenti grezzi — il modulo distintivo; appendice GPU

4 **Esplicabilità e governance**
Captum, fairness, PSI e la scheda di validazione per la Vigilanza

Consegnato: environment.yml · 12 notebook + appendice GPU · dataset pronti · template di scheda di validazione
Ipotesi di prassi (Gini, PSI, art. 178 CRR, PD a 12 mesi): da validare con la validazione interna prima dell'avvio

Date e orari del corso

Due edizioni · Quattro incontri per edizione

1ª EDIZIONE

- 5 novembre
- 13 novembre
- 24 novembre
- 3 dicembre

2ª EDIZIONE

- 6 novembre
- 11 novembre
- 26 novembre
- 30 novembre

ORARIO PER ENTRAMBE LE EDIZIONI

9.00 – 13.00

Pausa caffè di 10 minuti a metà mattina

La prima bozza di queste slide è stata generata utilizzando strumenti di AI sotto la direzione di Antonio Piemontese e in conformità alle sue istruzioni e linee guida generali e specifiche.

Il materiale è stato successivamente esaminato, rivisto e ulteriormente perfezionato attraverso ulteriori interazioni con gli strumenti di AI, sulla base delle osservazioni e delle richieste specifiche di modifica di Antonio Piemontese.

Durante l'intero processo, Antonio Piemontese ha mantenuto la responsabilità della direzione complessiva, dei contenuti, della revisione e dell'approvazione finale del materiale.

La presente dichiarazione è resa in conformità ai requisiti di trasparenza dell'AI Act dell'Unione europea.

DISCLAIMER

Modalità di erogazione del corso

1 Scelta della modalità

La modalità di erogazione di questo corso non è stata decisa da Overnet / Antonio Piemontese.

2 Requisiti di sicurezza

Essa recepisce i requisiti di sicurezza di Intesa Sanpaolo: impossibilità di installare software sui PC dei partecipanti, impossibilità / difficoltà ad accedere a siti Internet dai medesimi PC.

3 Dimostrazione commentata del codice

Il corso è perciò erogato in **modalità dimostrativa**: il docente mostra, esegue e commenta il codice, senza possibilità per i partecipanti di eseguirlo sui propri PC durante le lezioni.

4 Codice mostrato e consegnato

Su richiesta di ISP tutto il codice è comunque mostrato e consegnato. Potrà essere utilizzato in futuro da chi può installare software e accedere alla rete, anche lavorando da casa. **Il corso infatti rimane hands-on.**

5 Nota del docente

Come docente sono consapevole dei limiti didattici di tale scelta, imposta dagli stringenti e comprensibili vincoli di sicurezza.

Il corso risponde alle esigenze di Intesa Sanpaolo

Overnet · Deep Learning applicato al credito

Riprendiamo la slide iniziale

ESIGENZE FORMATIVE	RISPOSTA DEL CORSO
Approfondire il Deep Learning Il Machine Learning è già conosciuto	Focus su **reti neurali, sequenze transazionali** ed **embedding**.
Credito, PD e pattern recognition Comprendere i predittori rilevanti	Esempi sul **credito** e confronto con **XGBoost** per valutare il contributo del DL. (click per info)
Valutare la qualità dei modelli Performance delle probabilità di default	Discriminazione e calibrazione delle **PD; precision, recall** e **F1** accanto all'accuracy.
Spiegabilità, bias e Vigilanza Comprendere e motivare le scelte	**valori SHAP** e **Captum,** (Valori SHAP; Captum) stabilità delle spiegazioni e valutazione quantitativa dei **bias.** Prerequisito per Captum: **feature importance.**
Volumi e portafogli diversi Retail, Large Corporate e SME	Criteri di scelta adatti sia ai **grandi volumi transazionali** sia ai **portafogli contenuti.**
Didattica frontale e codice disponibile Partecipazione senza installazioni	**Demo** sul PC del docente e **notebook** con codice completo, riutilizzabile dopo il corso.

Python · scikit-learn · PyTorch

Formato richiesto: 4 mattine · 2 edizioni replicate · 15 partecipanti per edizione

Obiettivi formativi forniti a Overnet da Intesa Sanpaolo

Giuseppe Giarrizzo · Debora Giuliano · Marco Alberici (vice di Andrey Karpov)

Riunione con Overnet del 15 settembre 2026

Fonte delle esigenze: verbale Digit'Ed / ISP del 15 settembre 2026

Sequenze transazionali: dai movimenti alla PD

Un oggetto dati: i movimenti di conto e carte di un cliente, ordinati nel tempo e conservati evento per evento.

Cliente C-002 — ultimi movimenti

Data	Importo	Causale	Canale	Saldo dopo
03/09	−120 €	pagamento POS	carta	310 €
05/09	+1.800 €	stipendio	bonifico	2.110 €
06/09	−900 €	prelievo contante	ATM	1.210 €
12/09	−430 €	utenze	addebito	780 €
…	…	…	…	…

Tre caratteristiche

L'ordine conta
Stipendio → prelievo massiccio il giorno dopo.

Lunghezza variabile
Da poche decine a migliaia di movimenti per cliente.

Tempi irregolari
Ore o settimane tra eventi.
Δt = tempo dal movimento precedente.

Un'unica pipeline

1 · Movimento → vettore

Numerici:
importo con segno, saldo, Δt

Categorici:
causale, canale,
categoria merceologica → **embedding**

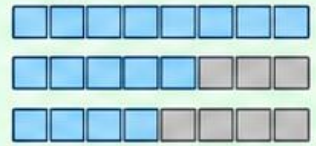
Vettore dell'evento



Embedding = vettori densi appresi durante l'addestramento, utili con molte categorie.

2 · Sequenze → batch

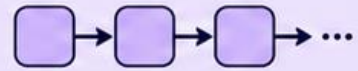
- Vettori nell'ordine temporale.
- **Padding:** uniforma le lunghezze.
- **Masking:** ignora le posizioni aggiunte.



Tensore del batch

3 · LSTM

La rete ricorrente legge i vettori uno dopo l'altro, nell'ordine.



4 · PD

Probabilità di default

Oggi: dati aggregati → XGBoost

- Medie, conteggi e utilizzi in una riga per cliente.
- L'ordine si perde negli aggregati semplici.

Nel corso: sequenze → embedding + LSTM

- Si conservano ordine e tempi degli eventi.
- XGBoost può usare caratteristiche temporali trasformate in colonne.

Mattina 3 · Confronto a tre

Sui dati retail ad alto volume, il valore aggiunto del deep learning si misura in punti di Gini.

Transaction sequences · Event sequences · Dati comportamentali sequenziali

Assunzioni

Assunzioni del corso

1	**Nessun dato reale della banca in aula:** si lavora su dataset pubblici e sintetici che ne replicano la struttura (transazioni di conto corrente e carte)	Assunzione prudenziale per riservatezza; se ISP mette a disposizione dati anonimizzati, i notebook sono adattabili
2	Obiettivo modellistico: **PD binaria a orizzonte fisso** (default sì/no entro 12 mesi dalla data di osservazione) — classificazione supervisionata con output probabilistico	ISP **non si è espresso** sulla forma del target: l'assunzione discende (a) dall'attività quotidiana dichiarata da ISP — modelli di PD costruiti con classificatori come XGBoost, Random Forest e alberi (vedi Vincolo 7–Vincolo 8), che trattano il problema come classificazione binaria con output probabilistico — e (b) dallo standard IRB della PD a 12 mesi (I5). Alternative come i modelli di sopravvivenza (*survival analysis*: stima del tempo al default anziché del sì/no a orizzonte fisso) o la PD multi-periodo restano fuori perimetro, salvo diversa indicazione
3	XGBoost presente **in ogni laboratorio come benchmark** (approccio *champion/challenger*: modello in produzione contro modello sfidante), mai come oggetto di insegnamento	Metodologia corretta e risposta alla domanda tipica della Vigilanza ("perché una rete invece di XGBoost?"); la letteratura mostra che sui dati tabellari il gradient boosting resta un benchmark severo per il deep learning: Grinsztajn et al. (2022), Shwartz-Ziv & Armon (2022), Borisov et al. (2024) — riferimenti completi più avanti (al notebook apposito)
4	Esercizi di fine capitolo **a difficoltà crescente**, con estensioni opzionali per i partecipanti con Python medio-alto	Gestione dell'eterogeneità dei livelli (dei partecipanti) dichiarata da ISP
5	Dataset distribuiti come **file pronti (CSV/Parquet)** dentro il materiale del corso	Evita registrazioni e autenticazioni Kaggle in aula (fonte classica di perdite di tempo)
6	Terminologia: italiano con **il termine inglese tra parentesi** alla prima occorrenza di ogni concetto tecnico	Letteratura, librerie e messaggi di errore del software sono in inglese

kaggle

CSV

Parquet

1 Perché dataset sintetici

La strategia dati del corso: nessun dato reale in aula, dataset pubblici dove bastano, sintetici dove servono

Dati reali della banca — esclusi dall'aula

- Riservatezza e GDPR: dati personali e bancari fuori dai sistemi della banca, in un'aula online con 30 partecipanti
- Iter di autorizzazione interno incompatibile con i tempi del corso
- Anche anonimizzati, i pattern di spesa restano re-identificabili: il rischio non si azzera

Dataset pubblici — utili solo dove bastano

- Transazioni bancarie realistiche non si trovano pubbliche — per gli stessi vincoli di riservatezza di cui sopra
- Struttura ed etichette lontane da quelle della banca: campi, causali, definizione di default
- Nel corso restano per il tabellare delle mattine 1–2 (Taiwan, Home Credit)

Transazioni sintetiche costruite ad hoc — la scelta per le sequenze (mattine 3 e 4)

Zero rischio privacy

Nessun dato personale: condivisibili con tutti i partecipanti e riutilizzabili dopo il corso

Struttura su misura

Replicano conti correnti e carte della banca: campi e causali nel lessico del team

Segnale controllato

Il pattern comportamentale è iniettato ad arte: difficoltà didattica calibrata, risultati spiegabili

Verità nota (ground truth)

Si verifica se il modello — e le spiegazioni Captum — ritrovano il segnale vero

Etichette conformi

Default art. 178 CRR, orizzonte a 12 mesi: lo stesso vocabolario usato con la Vigilanza

Dimensioni su misura

Campioni che girano su CPU in pochi minuti; scala libera per la demo GPU (anche su Colab)

Distribuite come file pronti (CSV/Parquet) dentro il materiale: zero registrazioni e autenticazioni in aula

Limite dichiarato: un dataset sintetico non dimostra le performance sul portafoglio reale — i numeri del corso illustrano il metodo. La validazione sui dati della banca avviene dopo, internamente, con gli stessi strumenti consegnati: notebook e scheda di validazione.

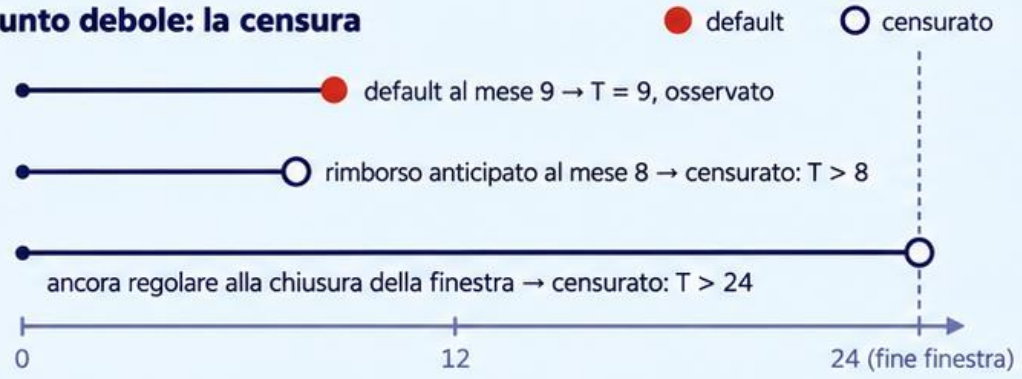
② Survival analysis: dal «sì / no» al tempo del default

Perché esiste, che cosa restituisce in più e perché nel corso resta un cenno

0/1 Il corso — classificazione binaria a orizzonte fisso

Domanda: «default entro 12 mesi?» — etichetta sì/no, lo standard dei modelli IRB
Output: una sola PD, all'oriizonte fisso di 12 mesi

Il punto debole: la censura

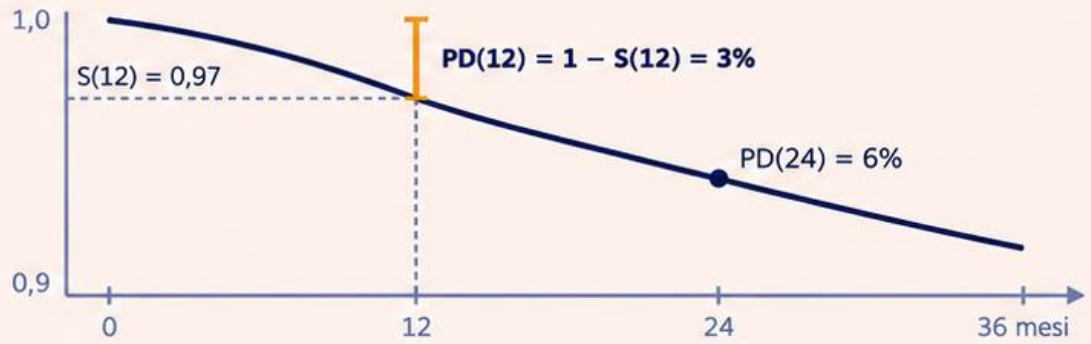


Su 100 prestiti osservati per 24 mesi: 5 default · 10 rimborsi anticipati · 85 ancora regolari
→ **95 censurati su 100**: il modello binario li esclude o li etichetta a forza

T L'alternativa — survival analysis (analisi di sopravvivenza)

Domanda: «quanto tempo al default?» — il target è il tempo all'evento T
La censura è informazione: «T > 8» entra nella stima, nulla viene scartato

Che cosa restituisce: la curva di sopravvivenza S(t) = P(T > t)



Un solo modello dà **l'intera struttura per scadenza** — fino alla PD lifetime di IFRS 9 (stage 2)
h(t), l'hazard: il tasso istantaneo di default fra i prestiti ancora «vivi» al tempo t

La famiglia di modelli — dal descrittivo al deep learning

Kaplan–Meier
stimatore non parametrico di S(t): la fotografia della coorte

Cox — hazard proporzionali
$h_0(t)\cdot\exp(\beta x)$, base comune per tutti: il cavallo di battaglia

Tempo discreto
logistica su righe «prestito-mese»: il ponte dalla pratica attuale

ML e deep learning
XGBoost: survival:cox, survival:aft; DeepSurv, DeepHit

Rischi concorrenti
default vs rimborso anticipato: modello di Fine–Gray

→ **Perimetro (A4):** il corso resta sulla PD binaria a 12 mesi — lo standard IRB e la pratica quotidiana del team.
La survival è l'estensione naturale quando serve l'intera curva (PD lifetime IFRS 9, pricing): il ponte è PD(H) = 1 − S(H).

2 PD multi-periodo: la struttura per scadenza

Le tre grandezze, a che cosa servono e come si costruiscono — la PD a 12 mesi del corso è il primo punto della **curva**

PD Le tre grandezze, con i numeri in mano



- Anno 1: cumulata = marginale = condizionata = **3%** (si parte tutti vivi)
- **PD marginale** (anno 2): 3 su 100 = **3%** — vista da oggi
- **PD condizionata** (anno 2): 3 su 97 = **3,09%** — fra i vivi a inizio anno
- **PD cumulata** (2 anni): 6 su 100 = 6% = 1 − S(24)

Concatenazione: PD cumulata (2 anni) = 3% + 0,97 × 3,09% = 6%

€ A che cosa serve la curva

1. **IFRS 9 — perdita attesa lifetime (stage 2)**
   PD marginale × esposizione × LGD per ciascun periodo futuro, attualizzate e sommate; per lo stage 1 basta la PD a 12 mesi
2. **Pricing dei prestiti pluriennali**
   lo spread deve coprire il rischio su tutta la vita del prestito, mentre l'ammortamento fa variare l'esposizione anno per anno
3. **Stress test e ICAAP**
   PD per ciascun anno dello scenario, condizionate alle variabili macro: il «forward-looking» richiesto anche da IFRS 9

La PD a 12 mesi del corso è il primo punto della curva: il resto si costruisce da lì.

Come si costruisce — quattro strade

Concatenazione di PD annuali
condizionate anno per anno, composte: $PD_1 + (1 - PD_1) \cdot PD_2$ = cumulata

Modelli a tempo discreto
logistica su righe «cliente-periodo», con l'età del rapporto tra i predittori

Survival analysis
S(t) in un colpo solo: tutte le grandezze discendono per formula (v. backup dedicato)

Matrici di migrazione dei rating
default come stato assorbente; la curva dalle potenze di M (ipotesi di Markov)

→ **Oggetto, non metodo:** la PD multi-periodo è il fabbisogno (la curva intera); survival, periodi discreti e migrazioni sono i modi di produrla.
Perimetro (A4): il corso resta sul primo punto — la PD binaria a 12 mesi, standard IRB; il ponte verso la curva è PD cumulata(t) = 1 − S(t).

3 Champion e challenger: XGBoost come metro di misura

La voce A5 del quadro, spiegata: che cosa significa, perché è stata scelta e che cosa dice la letteratura

VS Il meccanismo: la sfida in ogni notebook

CHAMPION
XGBoost
il modello in produzione, già padroneggiato dal team

VS

CHALLENGER
La rete neurale
MLP e LSTM: ciò che il corso costruisce mattina dopo mattina

L'arena: stessi dati, stesse metriche
Gini · PR-AUC · Brier score · test di calibrazione per fascia di rating

Tabella champion/challenger documentata — chiude ogni notebook
il confronto è scritto, non raccontato

✓ Vince il champion → esito difendibile, misurato ✓ Vince il challenger → adozione motivata

In entrambi i casi la domanda «perché una rete invece di XGBoost?» ha già la risposta scritta.

Perché questa impostazione

1. **È la metodologia corretta di adozione**
un nuovo modello entra in produzione solo se batte quello esistente sugli stessi dati: il challenger non parte mai alla pari

2. **La risposta alla Vigilanza è già pronta**
alla domanda tipica «perché una rete invece di XGBoost?» risponde la tabella di confronto di ogni notebook

3. **È onestà intellettuale**
sul tabellare di dimensioni medie il gradient boosting resta durissimo da battere: lo dice la letteratura qui sotto

XGBoost non è oggetto di insegnamento: entra in aula solo come metro di misura — e il team lo padroneggia già, quindi nessun tempo sprecato.

La letteratura che fa da arbitro — riferimenti completi nel §5 del quadro

Grinsztajn, Oyallon, Varoquaux (2022) — NeurIPS
benchmark su 45 dataset tabellari: i modelli ad albero restano lo stato dell'arte sulle dimensioni medie (~ 10k righe)

Shwartz-Ziv & Armon (2022) — Information Fusion
a parità di protocollo di tuning, XGBoost batte i modelli deep tabellari sulla maggior parte dei dataset

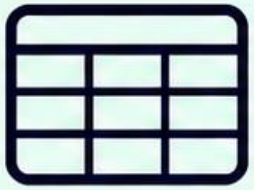
Borisov et al. (2024) — IEEE TNNLS
rassegna sistematica: il gradient boosting resta per lo più superiore sul tabellare supervisionato

→ **Il punto di questa assunzione:** XGBoost non si insegna — è il metro che rende ogni risultato del corso difendibile, qualunque sia il vincitore.
Dove cercare il valore delle reti: grandi volumi, sequenze grezze di transazioni, categoriche ad alta cardinalità — fuori dal perimetro di quei benchmark.

Tecniche già padroneggiate con scikit-learn — **XGBoost, Random Forest, alberi decisionali** — che **non sono oggetto del corso** (solo benchmark di confronto)

I dati

Dataset del corso

Dataset	Mattine	Caratteristiche e uso nel corso
 **Taiwan Credit Card Default** (UCI)	**1**	Storico **pagamenti mensili**; ideale per introdurre **metriche** e **primo MLP**
 **Home Credit Default Risk** (campione)	**2**	Ricco di variabili **comportamentali** e categoriche ad **alta cardinalità**; fornito come **file pronto (nessuna registrazione Kaggle)**
 **Transazioni sintetiche** (costruite ad hoc)	**3–4**	Replicano la struttura di **conti correnti e carte** della banca, con **segnale comportamentale controllato**; etichettate secondo le **ipotesi I4–I5**

Label e transazioni: due ruoli diversi

Lo storico dei prestiti fornisce la Y (che cosa predire); le transazioni sono una famiglia di X (con che cosa predirla)

Prestiti passati con esito osservato
rate pagate e saltate, recuperi, chiusure:
da qui nasce l'etichetta di ogni osservazione

fornisce →

Label — il target Y
default sì / no entro 12 mesi dall'osservazione
(art. 178 CRR, l'orizzonte dei modelli IRB)

I PREDITTORI — LE X

la label serve solo in addestramento (supervisione)

Dati della domanda e anagrafica
età, reddito dichiarato, forma giuridica, finalità

Storia creditizia e bureau
rate pagate o saltate finora, esposizioni in essere

Transazioni di conto e carte
entrate, saldo, utilizzo del fido, movimenti:
le X comportamentali — il focus del corso

Modello di PD — f(X)
oggi XGBoost, Random Forest;
nel corso anche le reti neurali

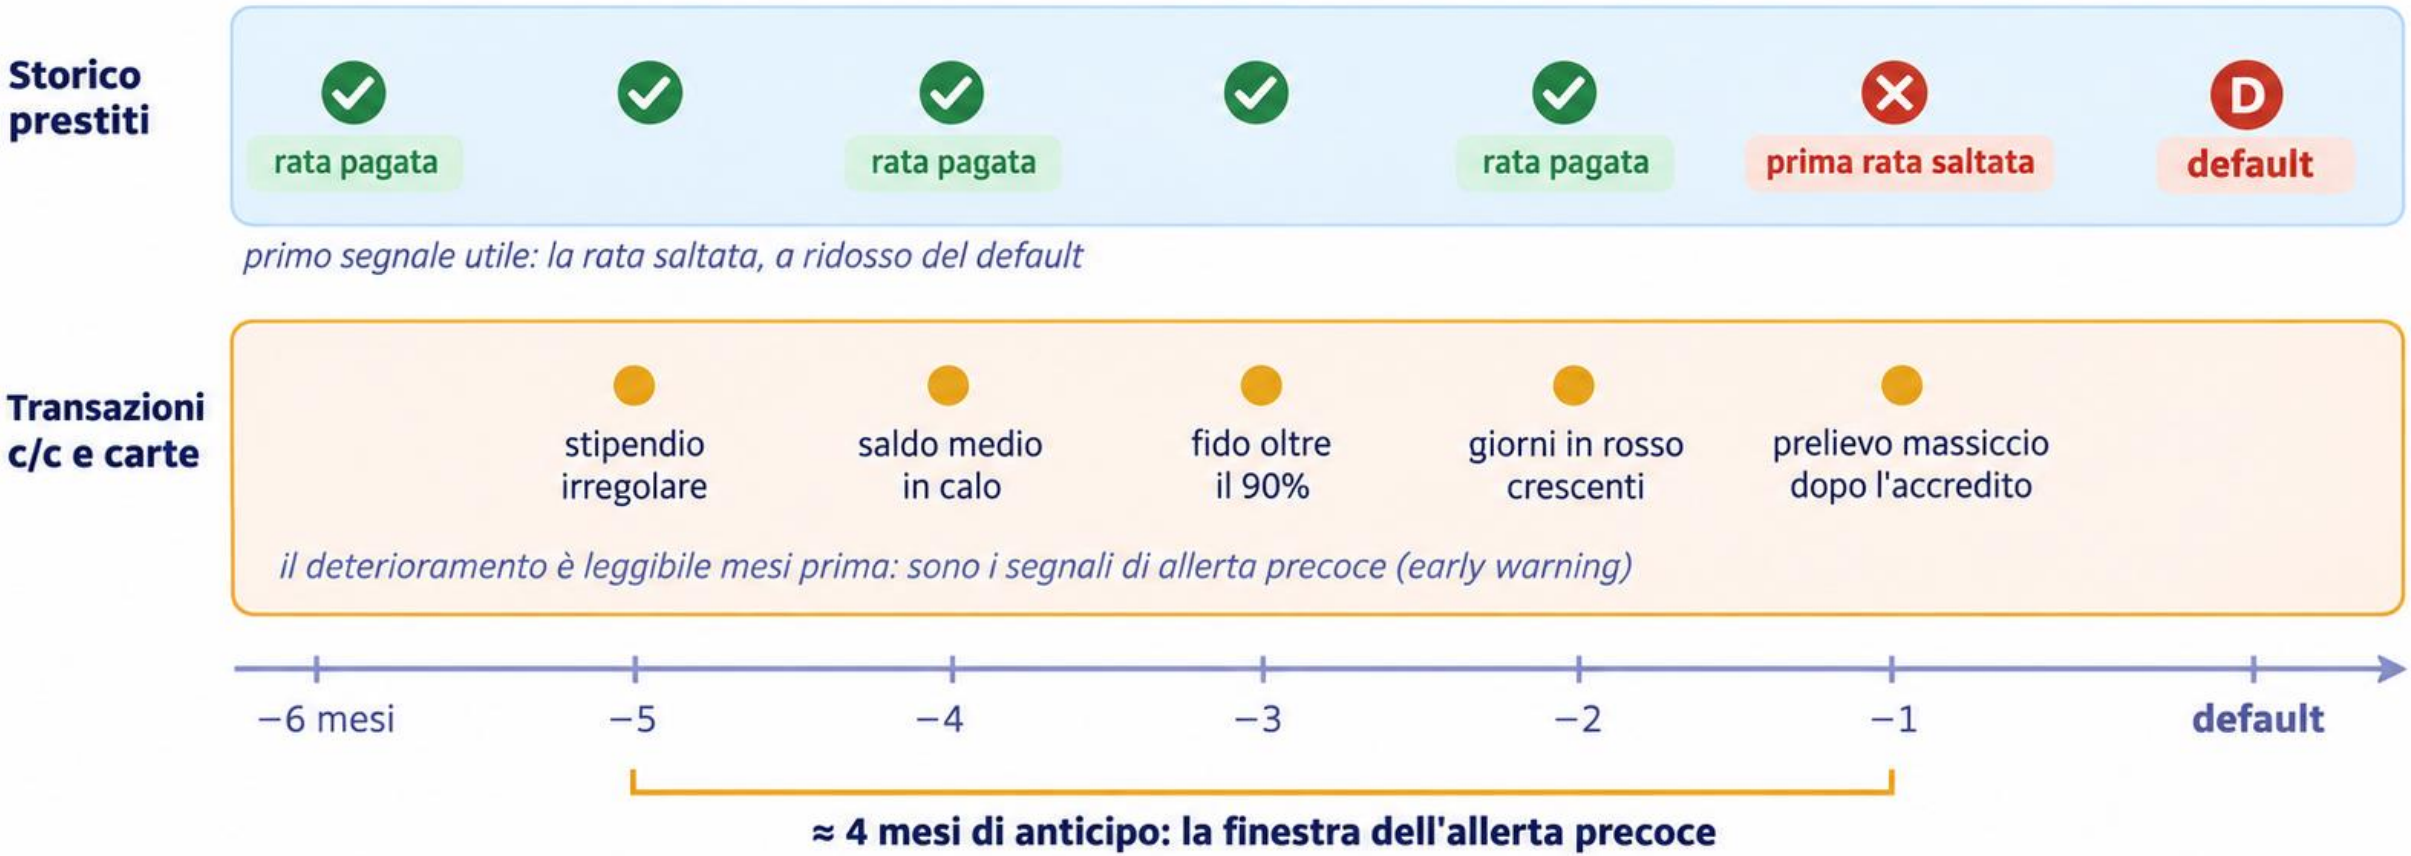
→

PD stimata
probabilità di default a 12 mesi
es. 2,8%

→ **Il punto:** senza la label non si addestra nulla — ma la label non predice: a predire sono le X.
Le transazioni sono le X comportamentali: contengono ciò che la sola storia di rimborso non può contenere.

Il segnale in ritardo e l'allerta precoce

La storia di rimborso vede il default quando arriva; le transazioni lo vedono maturare, mesi prima



→ **Evidenza classica:** Norden & Weber (2010), «Credit Line Usage, Checking Account Activity, and Default Risk of Bank Borrowers», The Review of Financial Studies, 23(10): conto e fido predicono e anticipano il default.

Due clienti identici per lo storico prestiti

Stessa storia di rimborso, rischio diverso: sono le transazioni a separarli

Ciò che vede lo storico prestiti

Cliente A	✓ ✓ ✓ ✓ ✓ ✓	rate sempre pagate, mai un ritardo
Cliente B	✓ ✓ ✓ ✓ ✓ ✓	rate sempre pagate, mai un ritardo

indistinguibili

✓ Cliente A — ciò che dicono le transazioni

- Stipendio accreditato regolarmente, ogni mese
- Saldo medio stabile: **2.300 €**
- Utilizzo del fido: **30%**
- Giorni in rosso nell'ultimo trimestre: **0**

PD bassa *profilo solido*

✗ Cliente B — ciò che dicono le transazioni

- Accredito dello stipendio cessato da **2 mesi**
- Saldo medio: **−410 €,** in calo da tre mesi
- Utilizzo del fido: **95%**
- Giorni in rosso nell'ultimo mese: **12**

PD alta *deterioramento in corso*

→ **La storia di rimborso li confonde, i movimenti li separano.**
Per questo i modelli comportamentali (behavioural scoring) usano le transazioni come predittori.

Copertura e frequenza: dove lo storico non arriva

Le transazioni valutano chi non ha storia creditizia e aggiornano la PD al ritmo dei movimenti, non delle rate

1 Copertura: il «thin file»

thin file = «fascicolo sottile»: poca o nessuna storia creditizia

Chi: nuovo correntista · giovane al primo credito · SME recente

Storico prestiti: vuoto
nessuna rata osservata — lo storico è muto

Conto corrente: pieno
movimenti ogni giorno — il cliente resta valutabile dai comportamenti

Con l'open banking (PSD2), i dati di conto sono accessibili — con il consenso del cliente — anche ad altri intermediari: chi li sfrutta valuta chi gli altri non sanno valutare.

2 Frequenza: dal mensile al giornaliero

Storia di rimborso — un aggiornamento al mese (la rata)



12 / anno

Transazioni — un aggiornamento al giorno



365 / anno

PD «point-in-time»: aggiornata di continuo

point-in-time = riferita alla condizione attuale del cliente, non a una media di lungo periodo. Risultato: monitoraggio continuo del portafoglio, non solo valutazione al momento della concessione.

A·B

Application scoring — la PD stimata alla richiesta di credito, con i dati della domanda e del credit bureau.
Behavioural scoring — la PD ricalcolata periodicamente sul cliente esistente, dal comportamento osservato: è il territorio del team (transazioni a grandi volumi) e del corso.

Dal livello alla dinamica: il passo della mattina 3

Le transazioni sono già predittori oggi, in forma aggregata; la sequenza grezza aggiunge la dinamica

Oggi — transazioni aggregate

Movimenti di conto e carte
migliaia di righe per cliente

↓

Aggregazione su finestre
medie, conteggi, saldo, utilizzo del fido

↓

Una riga di tabella per cliente
i livelli entrano; l'ordine degli eventi no

↓

XGBoost — il champion di oggi

Mezzo punto già risolto: le aggregate anticipano la storia di rimborso — ma la dinamica si perde

Mattina 3 — la sequenza grezza

Movimenti ordinati nel tempo
la sequenza resta intera: nessuna aggregazione

↓

LSTM — rete ricorrente
legge i movimenti uno dopo l'altro, nell'ordine

↓

PD con la dinamica dentro
anche l'ordine degli eventi è un predittore

Il pattern che le medie distruggono — «stipendio, poi prelievo massiccio il giorno dopo, ogni mese» — qui resta leggibile.

Il confronto con XGBoost resta in ogni laboratorio: il valore aggiunto si misura in punti di Gini

In sintesi: le transazioni aggregate anticipano già la storia di rimborso; la sequenza completa il lavoro, conservando l'ordine degli eventi — ed è esattamente il passo che il corso compie nella terza mattina.

Dati tabellari vs dati con struttura

Lo stesso cliente, due forme del dato: perché XGBoost resta il benchmark sulla tabella — e perché la rete vince sulla sequenza

DATI TABELLARI — il formato di oggi

cliente	età	saldo 3m	n. trans. 3m	fido	default 12m
C-001	44	2.350 €	87	62%	no
C-002	31	−410 €	212	94%	sì

- Una riga = un'osservazione **indipendente** (un cliente, un'esposizione)
- Colonne **eterogenee**: tipi, scale e significati diversi tra loro
- **Nessuna struttura** tra le colonne: il loro ordine non conta

Il territorio degli alberi

XGBoost lavora per soglie, colonna per colonna: nessuno scaling, robustezza alle feature inutili, scale diverse senza problemi.

Letteratura 2022–2024: un benchmark severissimo per il deep learning.

DATI CON STRUTTURA — la sequenza dei movimenti

Prendiamo il cliente **C-002** della tabella a sinistra e torniamo ai suoi dati grezzi, prima di ogni aggregazione: i movimenti del conto, ordinati nel tempo.

03/09 · POS **−120 €** ▸ 05/09 · stipendio **+1.800 €** ▸ 06/09 · prelievo **−900 €** …

il pattern: stipendio, poi prelievo massiccio il giorno dopo — ogni mese

Oggi — aggregazione in una riga di tabella
Medie e conteggi — saldo −410 €, 212 transazioni — generano la riga C-002 della tabella a sinistra: l'ordine sparisce, il pattern non si vede più.

Mattina 3 — la rete legge la sequenza com'è
La LSTM (rete ricorrente) elabora i movimenti uno dopo l'altro, nell'ordine in cui avvengono: il pattern resta e contribuisce alla stima della PD.

Il territorio delle reti

Vantaggio strutturale: la rete riceve in input la sequenza, XGBoost no — per lo stesso motivo le reti dominano su immagini e testo, dati con struttura.

→ **In sintesi:** finché il dato resta «una riga per cliente» — la tabella a sinistra — XGBoost è il benchmark da battere (mattina 2). Quando il dato è la sequenza grezza dei movimenti — la colonna a destra — la rete ha un vantaggio strutturale: è il modulo della mattina 3.

Letteratura: Grinsztajn, Oyallon, Varoquaux (2022), NeurIPS · Shwartz-Ziv & Armon (2022), Information Fusion · Borisov et al. (2024), IEEE TNNLS

L’organizzazione del corso

Come lavoreremo: tre principi di fondo

Un corso costruito per chi i modelli di PD li sviluppa già — partendo dagli strumenti che usate ogni giorno

1 PRINCIPIO 1

Onestà sul tabulare

Sui dati aggregati i gradient boosted trees restano durissimi da battere (Grinsztajn 2022; Gunnarsson 2021 sul credit scoring). Per questo il vostro XGBoost resta in campo per tutto il corso: ogni rete dovrà guadagnarsi il posto, dati alla mano.

Benchmark sempre attivo

2 PRINCIPIO 2

Il DL dove vince davvero

Non chiederemo a una rete di battere XGBoost sulle feature di oggi: impareremo rappresentazioni dalle sequenze di transazioni di c/c e carte, embedding di categoriche ad alta cardinalità, transfer tra segmenti, loss e calibrazione su misura.

Sequenze transazionali

3 PRINCIPIO 3

La lingua della Vigilanza

Ogni modello che costruiremo nasce già difendibile: discriminazione e calibrazione misurate bene, spiegabilità, bias, riproducibilità. E ogni modulo si chiude con la domanda: «che cosa chiederebbe la Vigilanza qui?».

Difendibile in ispezione

Nessuna promessa ingenua: su una matrice di feature aggregate, una rete raramente batte il vostro XGBoost.
La promessa vera: deep learning dove crea valore nuovo — valutato e spiegato come la Vigilanza si aspetta.

4 mattine online · laboratori hands-on in PyTorch su dati pubblici · l'harness di valutazione costruito in aula resta a voi

I cinque fili conduttori delle quattro mattine

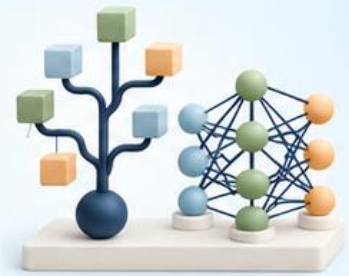
Il metodo che terremo fermo dal primo all'ultimo laboratorio

1	**Il vostro XGBoost, campione in carica**	Ogni tecnica di deep learning dovrà batterlo o affiancarlo, numeri alla mano, su un benchmark sempre attivo. È la logica del challenger model che i supervisori apprezzano.
2	**Le metriche giuste per la PD**	Con un default rate al 2%, il modello «nessuno fallisce» fa il 98% di accuracy. Lavoreremo con AUC/Gini, KS, PR-AUC e calibrazione (Brier, reliability, test di Jeffreys), con validazione out-of-time e stabilità (PSI).
3	**Spiegare le reti, su due binari**	SHAP e Integrated Gradients sulle reti (con Captum), conoscendone i caveat; e modelli auto-interpretabili: NAM, vincoli di monotonicità, ibrido «rete come feature extractor + modello finale semplice».
4	**Il bias, misurato e mitigato**	Metriche per gruppo, proxy negli attributi transazionali, mitigazioni (reweighing, adversarial debiasing), teoremi di impossibilità; il quadro regolamentare: AI Act, EBA, BCE.
5	**Tre segmenti, tre strategie**	Retail: il DL paga (volumi, dati granulari). Large corporate low-default: il nodo è statistico (Pluto–Tasche), non architetturale. SME: transfer e multi-task dal retail, da esplorare insieme come direzione sperimentale.

Riferimenti che incontreremo: Grinsztajn et al. 2022 · Gunnarsson et al. 2021 · Guo et al. 2017 · Agarwal et al. 2021 (NAM) · EBA ML-IRB 2021/2023 · ECB Guide to Internal Models

Tre scelte di fondo

Quando una rete neurale migliora la stima della probabilità di default (PD)?



01 IL CONFRONTO

XGBoost in ogni laboratorio

Su dati tabellari di medie dimensioni il gradient boosting è competitivo. Sullo stesso campione di test si misura se la rete migliora la stima.

CHAMPION E CHALLENGER
Il modello in produzione è il champion. La rete candidata è il challenger.



02 LA STRUTTURA DEI DATI

Reti per sequenze e categorie

RNN e LSTM leggono la sequenza dei movimenti su conti e carte. Gli embedding apprendono vettori densi per migliaia di causali o settori.

APPRENDIMENTO MULTI-TASK
Più obiettivi di previsione condividono una rappresentazione appresa dei dati.



03 LA QUALITÀ DELLA PD

Le metriche dalla prima mattina

Prima di addestrare una rete, si valuta se la PD ordina i clienti per rischio e se le probabilità stimate corrispondono alle frequenze di default osservate.

IMPIEGO DELLE STIME
La calibrazione della PD conta per il pricing del credito e il calcolo del capitale.

Riferimento sui dati tabellari · Grinsztajn, Oyallon e Varoquaux, NeurIPS 2022.

Cinque punti guida

Le verifiche con cui motivare le scelte di modello alla validazione interna e alla Vigilanza.

01 **Valutare discriminazione e calibrazione**

ROC-AUC, Gini = 2 × AUC − 1, PR-AUC e KS per la discriminazione. Curve e test binomiali per fascia di rating per la calibrazione. Brier score per l'errore complessivo delle PD.

02 **Confrontare ogni rete con XGBoost**

Stessi clienti, stessa data di previsione e stesso orizzonte di default. Se disponibile, si include anche il modello in produzione.

03 **Spiegare le stime lungo tutto il corso**

Da SHAP a Captum (Integrated Gradients, GradientShap, DeepLiftShap). Si verificano i vincoli di monotonicità e la stabilità delle spiegazioni nel tempo e tra campioni.

04 **Misurare e mitigare i bias**

Con Fairlearn si testano le mitigazioni confrontando tra gruppi i tassi di approvazione (demographic parity) e i tassi di veri e falsi positivi (equalized odds).

05 **Adattare il modello al portafoglio**

Nel retail si testano reti su milioni di movimenti. Con pochi default (PMI e large corporate), il rischio di overfitting suggerisce reti regolarizzate o modelli classici.

ESEMPIO / 100 CLIENTI

Il limite dell'accuracy

Il modello assegna a tutti la classe «nessun default».



● 98 regolari ◆ 2 in default

98% accuracy

0 su 2 default rilevati

Strumenti di laboratorio · XGBoost, PyTorch, Captum e Fairlearn.

Contesto regolamentare e quadro normativo

INTESA SANPAOLO

Contesto regolamentare

Credit Risk Modeling & Scoring

Controlli attenti della Vigilanza | Valutazioni tecniche e rigorose



Metriche di performance

Qualità delle previsioni



Metriche di interpretabilità e spiegabilità

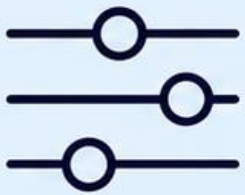
Comprensione delle previsioni e delle motivazioni



Metriche di bias

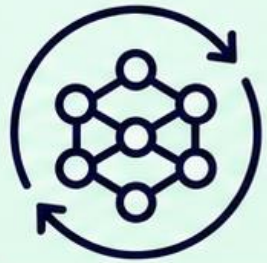
Misurazione delle distorsioni

Possibili richieste di affinamento dei modelli | Il «fine-tuning» tradotto in pratica nel corso



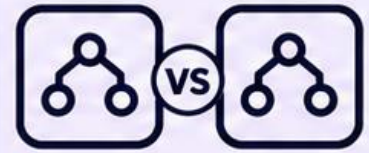
Ricalibrazione

Riallineare le probabilità di default stimate al rischio osservato.



Retraining

Riaddestrare il modello, ad esempio su dati aggiornati.



Challenger model

Confrontare il modello in uso con un modello alternativo.



Tre modalità di intervento da distinguere e valutare

Soglie e test di Vigilanza

#	Ambito	Ipotesi adottata
I1	Discriminazione	**Gini** (= 2·AUC − 1) come metrica principale, con lo schema "a semaforo" di prassi: sotto 40% debole, 40–60% accettabile, sopra 60% buono. Avvertenza esplicita per i portafogli *low-default* (pochi default osservati, es. large corporate): stime del Gini instabili, test a bassa potenza
I2	Stabilità	**PSI** (*Population Stability Index*, indice dello spostamento della popolazione corrente rispetto a quella di sviluppo) con soglie classiche: 0,10 (stabile) e 0,25 (deriva significativa)
I3	Calibrazione	**Test binomiale** e **test di Jeffreys** per fascia di rating — quest'ultimo previsto dalle istruzioni BCE per il *validation reporting* dei modelli interni — più Hosmer–Lemeshow come alternativa classica

Soglie e test di Vigilanza: le ipotesi I1–I3, spiegate

Ipotesi di prassi europea da validare — aggiornate con i chiarimenti su potenza statistica (I1) e drift (I2)

I1 Discriminazione — il Gini

Gini = 2·AUC − 1: lo schema a semaforo di prassi

< 40% · debole | **40–60% · accettabile** | **> 60% · buono**

Portafogli low-default (pochi default)

«Bassa potenza» non è un test: è il difetto dei test usuali — con pochissimi default osservati, quasi nulla risulta statisticamente significativo

- Intervalli su AUC/Gini: DeLong o bootstrap
- Champion vs challenger: test di DeLong per AUC correlate, più bootstrap della differenza
- PD prudenziale: Pluto–Tasche — limite superiore di confidenza, anche con zero default
- Pooling di anni, accorpamento di classi di rating, benchmark esterni

Si giudica l'intervallo, non il punto.

I2 Stabilità — il PSI

PSI = Σ (p − q) · ln(p/q), sommando sulle fasce
In linguaggio ML è il **data drift** (deriva dei dati)

< 0,10 · stabile | **0,10–0,25 · attenzione** | **> 0,25 · deriva**

Che cosa vede il PSI — e che cosa no

Data drift — cambia la distribuzione delle X	✓
Score drift — cambia la distribuzione del punteggio	✓
Prior shift — cambia il tasso di default	~
Concept drift — cambia la relazione X → default	✗

Il concept drift si scopre solo con il backtesting nel tempo di Gini e calibrazione: PSI e monitoraggio delle performance viaggiano insieme (governance, mattina 4)

Il PSI è la divergenza di Jeffreys — lo stesso Jeffreys del test di calibrazione: due oggetti, un cognome

I3 Calibrazione — test per fascia

La PD stimata deve corrispondere alle frequenze osservate, fascia di rating per fascia di rating

Test di Jeffreys — il riferimento BCE
previsto dalle istruzioni per il validation reporting; bayesiano (distribuzione Beta): regge bene anche le numerosità piccole dei low-default

Test binomiale — il classico
su pochi default usare la versione esatta (Clopper–Pearson), mai l'approssimazione normale

Hosmer–Lemeshow — l'alternativa storica
citata per completezza, oggi di contorno

Su un portafoglio low-default, discriminazione e calibrazione condividono lo stesso limite: pochi eventi, intervalli larghi

→ **Ipotesi di prassi, non norma:** valori dichiarati come tali in aula, da confermare con la funzione di validazione interna prima dell'avvio.
La sostituzione è un intervento minimo sui materiali: soglie e test sono parametri dei notebook, non architettura del corso.

definizione di default ed orizzonte della PD

I4 Definizione di default



Quella regolamentare europea dell'**art. 178 CRR** (*Capital Requiremente Regulation*, il regolamento europeo sui requisiti di capitale):

90 giorni di arretrato rilevante (*past due*) **oppure** improbabile adempimento (*unlikely to pay*, UTP),

con le soglie di rilevanza **EBA**:

100 € per il retail,

500 € per il non retail,

più l'**1%** relativo dell'esposizione

I5 Orizzonte della PD



12 mesi, target binario "default entro 12 mesi dalla data di osservazione", standard dei modelli **IRB** (*Internal Ratings-Based*, i modelli interni autorizzati per il calcolo del capitale).

Cenno in teoria alla PD *lifetime* richiesta da IFRS 9 per i crediti in stage 2

I6 Etichettatura dei dataset

I dataset sintetici vengono etichettati secondo I4–I5, così il vocabolario del corso coincide con quello usato dai partecipanti nei confronti della Vigilanza

Quadro normativo citato nei materiali

CRR

(Capital Requirements Regulation);

linee guida EBA sulla stima della PD:

EBA/GL/2017/16

(EBA = Autorità Bancaria Europea);

istruzioni **BCE** sul ***validation reporting*** dei modelli interni.

I tre riferimenti riguardano **le regole da rispettare, il modo di stimare il rischio e i controlli da documentare alla Vigilanza**. Sono collegati, ma svolgono funzioni diverse.

1. CRR: il quadro delle regole prudenziali

CRR significa *Capital Requirements Regulation*. È il **Regolamento europeo n. 575/2013**, successivamente modificato, che stabilisce requisiti prudenziali per le banche: in particolare, quanto capitale devono detenere rispetto ai rischi assunti, insieme a requisiti di liquidità e altri vincoli. L'obiettivo è assicurare che dispongano di risorse adeguate per assorbire le perdite e mantenere la propria solidità.

Per un corso sui modelli di rischio di credito, il CRR è rilevante perché stabilisce **che cosa si intende per default** e disciplina l'utilizzo dei modelli interni nel calcolo dei requisiti patrimoniali.

Per esempio, l'articolo 178 considera il default quando la banca ritiene improbabile che il debitore paghi integralmente senza ricorrere ad azioni come l'escussione delle garanzie, oppure quando esiste un arretrato rilevante superiore a 90 giorni. Questa definizione condiziona direttamente la costruzione della variabile da prevedere: prima di stimare la probabilità di default, occorre identificare correttamente quali osservazioni rappresentano un default.

Il CRR prevede inoltre requisiti di validazione dei modelli interni, affinché le stime utilizzate nel calcolo del capitale siano adeguate, robuste e affidabili.

2. Linee guida EBA: i criteri tecnici per stimare il rischio

EBA significa *European Banking Authority*, cioè **Autorità Bancaria Europea**. Le linee guida indicate nella slide, **EBA/GL/2017/16**, precisano i criteri per stimare i parametri di rischio nell'approccio IRB, basato sui rating interni. Riguardano la **PD**, la probabilità di default, ma anche la **LGD**, la perdita in caso di default, e il trattamento delle esposizioni già in default. Il loro obiettivo è rendere le stime più coerenti e confrontabili fra banche.

Sul piano operativo, affrontano questioni molto vicine al lavoro di modellazione: qualità e rappresentatività dei dati, coerenza della definizione di default, calcolo dei tassi di default, calibrazione delle probabilità e margini di prudenza necessari per tenere conto dell'incertezza.

Una distinzione centrale è quella fra **ordinare correttamente i clienti per rischio** e **assegnare loro probabilità corrette**. Un modello può riconoscere bene quali clienti sono più rischiosi e, contemporaneamente, attribuire probabilità troppo basse a tutti.

Per la PD prudenziale, la calibrazione fa riferimento al tasso di default medio di lungo periodo, ricavato da osservazioni annuali: **la probabilità riguarda un anno, mentre la storia utilizzata per stimarla copre più anni**.

Le linee guida hanno una natura diversa da un regolamento: autorità competenti e istituzioni finanziarie devono compiere ogni sforzo per conformarsi; per le autorità è previsto il meccanismo *comply or explain*, ossia dichiarare la conformità oppure motivare la mancata adesione.

3. Istruzioni BCE: come comunicare i risultati della validazione

Qui la **Banca Centrale Europea** interviene nella sua funzione di **vigilanza bancaria**.

La banca svolge la validazione interna dei propri modelli e ne documenta i risultati. La BCE richiede agli enti significativi autorizzati a utilizzare l'approccio IRB anche un insieme comune di informazioni, da trasmettere annualmente insieme alle relazioni di validazione. Questo è il senso del *validation reporting*: **presentare alla Vigilanza gli esiti dei controlli secondo definizioni, campioni e schemi condivisi**, così da renderli confrontabili.

Per un modello di PD, le verifiche comprendono, fra l'altro:

- **Capacità discriminante:** quanto bene il modello distingue i debitori che andranno in default dagli altri.
- **Calibrazione:** quanto le probabilità assegnate risultano coerenti con i default osservati.
- **Stabilità:** come cambiano nel tempo i rating e la loro distribuzione.

Le istruzioni specificano come svolgere determinate analisi e come riportarne i risultati. La responsabilità della validazione complessiva resta alla banca; gli schemi standardizzati forniscono alla BCE elementi utili per il monitoraggio. Le istruzioni, inoltre, dichiarano di non costituire esse stesse un atto giuridico vincolante: servono ad assistere gli enti nell'adempimento delle decisioni di vigilanza che richiedono tali informazioni.

Tecnologia

Tecnologia del corso



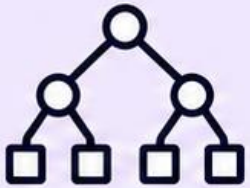
PyTorch (build CPU)

Framework di deep learning: MLP tabellari, embedding, LSTM su sequenze



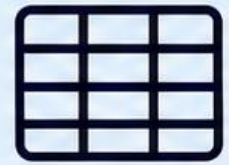
scikit-learn

Preprocessing, regressione logistica (baseline), metriche, calibrazione



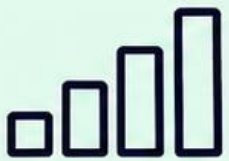
XGBoost

Benchmark/challenger in ogni laboratorio



pandas

Manipolazione dei dati tabellari e delle sequenze



SHAP

Interpretabilità del champion XGBoost (continuità con la pratica attuale)



Captum

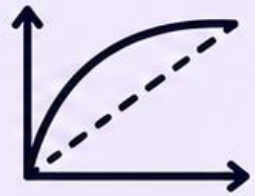
Interpretabilità delle reti PyTorch: DeepSHAP, GradientSHAP, Integrated Gradients



Fairlearn

*una libreria Python open source (nata in Microsoft, oggi progetto comunitario) che serve a **misurare** e a **mitigare** il bias di un modello di machine learning*

Metriche di fairness (demographic parity, equalized odds) e mitigazioni



matplotlib

Grafici: curve ROC, curve di calibrazione, curve di apprendimento



`environment.yml`: la «ricetta» dell'ambiente conda

Elenco dei pacchetti con **versioni fissate:** tutti i partecipanti di entrambe le edizioni lavorano nello **stesso ambiente.**

Un ambiente Python: tre componenti

Interprete + libreria standard + eventuali pacchetti aggiuntivi

1 Interprete Python

Esegue il codice ed è associato a una specifica versione di Python.

Su Windows: `python.exe`

2 Libreria standard

Funzionalità distribuite con Python, organizzate in moduli e package.

`site` · `os` · `sys` · `json` · `venv`

3 Pacchetti aggiuntivi

Componenti installate nell'ambiente oltre alla libreria standard.

`pip` · `numpy` · `pandas` · `torch`

Possono variare da un progetto all'altro.

Modulo e package: la struttura del codice

- **Modulo:** unità importabile, spesso un file `.py`.
- **Package:** un particolare tipo di modulo che può contenere sottomoduli e altri package.
- Moduli e package possono appartenere alla libreria standard oppure essere aggiuntivi.

site, pip ed ensurepip

- `site` → libreria standard: configura i percorsi di importazione.
- `pip` → pacchetto aggiuntivo: installa i pacchetti.
- `ensurepip` → libreria standard: predispone pip nell'installazione o nell'ambiente virtuale.
- pip è un progetto indipendente, spesso già fornito con Python.

L'interprete e i suoi pacchetti

```
python -m pip install pandas
```

Il comando esegue pip usando l'interprete individuato da python.
Un pacchetto deve essere disponibile nell'ambiente che esegue il programma.

Un ambiente per ogni progetto

La scomposizione è logica: con venv, la libreria standard è condivisa con l'installazione di base; lo spazio per i pacchetti aggiuntivi è specifico dell'ambiente.

Fonti: docs.python.org (libreria standard, glossario, site, ensurepip, venv) · pip.pypa.io (User Guide)

L'ecosistema Python su Windows

Miniconda, Conda, VS Code e Jupyter • Guida operativa per il corso

Windows 10/11 • Windows Terminal con profilo Prompt dei comandi (cmd)

per maggiori informazioni vedi il file md «installazione_python_windows_miniconda_vscode_jupyter_v14»

01 Installare e inizializzare

VS Code + Miniconda 64 bit (Just Me).
Miniconda include Python e Conda.
Da Miniconda Prompt, una **sola volta**:

```
conda init cmd.exe
```

Chiudere e riaprire Windows Terminal nel profilo cmd.

02 Creare e attivare myenv

Un ambiente dedicato al corso: non lavorare in base.

```
conda create -n myenv -c conda-forge --override-channels python=3.11
conda activate myenv
```

Usare conda-forge come unico canale Conda.

03 Isolare e verificare Python

```
set PYTHONNOUSERSITE=1
python -c "import sys; print(sys.executable)"
```

Escludere i pacchetti dello user-site.
set vale solo per la sessione corrente.
Il percorso dell'interprete deve appartenere a myenv.

04 Installare i pacchetti nell'ambiente attivo

Prima Conda, incluso ipykernel; poi pip solo per ciò che manca.

File del corso, dalla cartella **padre**:

Conda: `requirements_TM_conda.txt` • opzione `--file`

pip: `requirements_TM_pip.txt` • opzione `-r`

Con pip: prima `--dry-run`, poi installazione.
Usare sempre la forma `python -m pip`.
Non alternare i due gestori sullo stesso package.

05 Preparare Visual Studio Code

Installare le estensioni Microsoft:
Python • Pylance • Python Debugger
Python Environments • Jupyter

Chiudere tutte le finestre di VS Code prima di avviarlo dal terminale dell'ambiente.

06 Scegliere interprete e kernel

Per i notebook **.ipynb**:

```
Select Kernel → Python Environments.. → myenv
```

Controllare il nome e il percorso del kernel.
Per i file **.py**:

```
Python: Select Interpreter → myenv
```

Interprete = Python utilizzato.
Kernel = sessione che esegue le celle e conserva le variabili.

A ogni sessione

```
conda activate myenv
set PYTHONNOUSERSITE=1
cd C:\CorsoPython
code .
```

Aprire il notebook e verificare il kernel myenv.

Al termine: `conda deactivate`

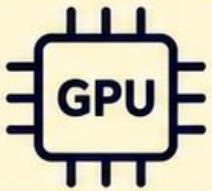
⚠ **Da evitare nel corso:** pip install senza `python -m`, `--user`, `!pip` e `!conda`. Dopo modifiche ai pacchetti, riavviare il kernel.

GUIDA RAPIDA IN 5 REGOLE

Come installare correttamente l'ecosistema Python su Windows

✕ COSA NON FARE		✓ COSA FARE
Installare Python da `python.org` oppure usare il Python pre-installato	1	**Installare Miniconda dal sito ufficiale** Miniconda è una distribuzione Python `www.anaconda.com/download`
Lavorare su un unico ambiente Python in cui si installa tutto	2	**Creare un ambiente `conda` per ogni progetto/iniziativa** In alternativa: ambiente virtuale con `venv`
Installare i package con il comando `pip` da solo ~~`pip install <package>`~~	3	**Installare sempre i package con:** `> python -m pip install <package>`
Installare i package dall'IDE Ad esempio dall'interfaccia di Visual Studio Code	4	**Installare i package da terminale** Ad esempio dal terminale di Visual Studio Code Sempre dalla riga di comando, **con l'ambiente virtuale attivato**
Avviare Visual Studio Code da Windows Menu Start o icona sul desktop	5	**Avviare Visual Studio Code da terminale** `> code`

Strumenti di lavoro

Strumento	Uso nel corso
 **Visual Studio Code**	IDE di riferimento per l'esecuzione dei notebook
 **conda**	Gestione dell'ambiente (creazione da `environment.yml`)
 **Jupyter notebook**	Formato di tutti i laboratori (notebook **interamente commentati in italiano**)
 **Google Colab**	Replica dell'**appendice GPU** per chi non dispone di scheda locale (**GPU T4 gratuita**)
 **CUDA**	Piattaforma **NVIDIA** che permette a **PyTorch** di usare la GPU — **solo nell'appendice dedicata**